



# » Лекционен курс » Въведение в генеративния ИИ



## Генеративно моделиране >

# Регистрация

Registration for: ВГИИ

Втора седмица



Short URL: <https://tinyurl.com/2b3omtuh>

Start at: 19-04-2024 09:15

Status: CREATED

End at: 19-04-2024 10:15

Registrations: 0



# Въведение

- » Генеративният изкуствен интелект (ГИИ) е една от **най-революционните технологии** на нашето време, **трансформираща** начина, по който **взаимодействаме с машините**.
- » Неговият потенциал да **революционизира начина**, по който живеем, работим и играем, е бил обект на безброй разговори, дебати и прогнози.
- » Но какво ще стане, ако тази мощна технология има **още по-голям потенциал**?
- » Какво ще стане, ако възможностите на ГИИ се простират отвъд сегашното ни въображение?
- » Бъдещето на ГИИ може да е по-вълнуващо, отколкото някога сме смятали за възможно...



# Творческото начало при хората

- » От най-ранните ни дни ние търсим възможности за генериране на оригинални и красиви творения.
- » За **първобитните хора** това е било под формата на **пещерни рисунки**, изобразяващи диви животни и абстрактни шарки, създадени с пигменти, поставени внимателно и методично върху скала.
- » **Романтичната епоха** ни даде майсторството например на **симфоните** на Чайковски с тяхната способност да вдъхновяват чувства на триумф и трагедия чрез звукови вълни, изтъкани заедно, за да образуват красиви мелодии и хармонии.
- » А напоследък се оказва, че бързаме към книжарниците в полунощ, за да купим **истории за измислен магьосник**, защото комбинацията от букви създава разказ, който ни кара да обърнем страницата и да разберем какво се случва с нашия герой.





# Творческото начало при хората

- » Ето защо не е изненадващо, че човечеството започна да задава основния въпрос за творчеството: можем ли да създадем нещо, което **само по себе си е творческо**?
- » Това е въпросът, на който ГИИ се стреми да отговори.
- » С последните постижения в методологията и технологията, ние вече сме в състояние да изградим машини, които могат да **рисуват** оригинални произведения на изкуството в даден стил, да **пишат** съгласувани текстови блокове с дълготрайна структура, да **композират** музика, която е приятна за слушане, както и да **разработват** печеливши стратегии за сложни игри чрез генериране на въображаеми бъдещи сценарии.
- » Това е само **началото на генеративна революция**, която няма да ни остави друг избор, освен да намерим отговори на някои от най-големите въпроси относно **механиката на творчеството**.



**Какво е генеративно моделиране?**

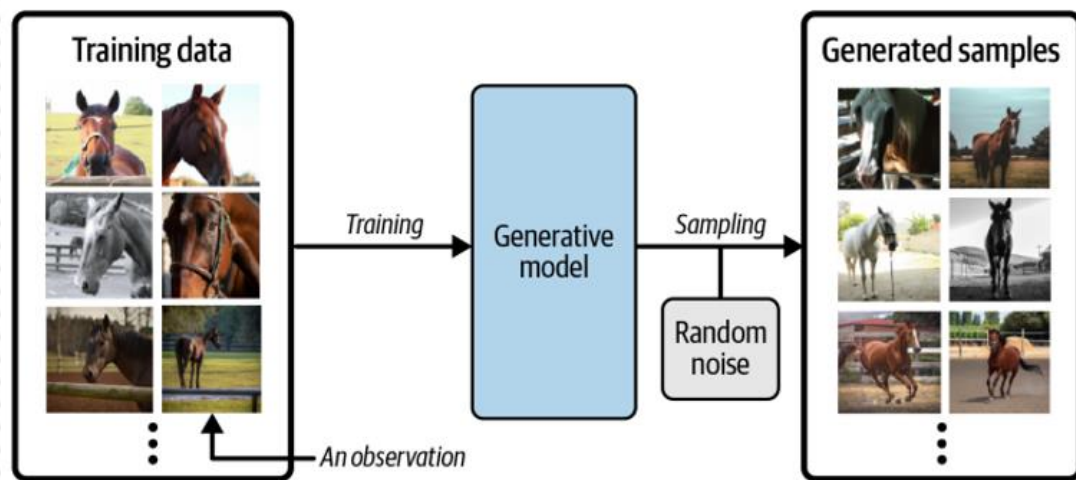


# Общо определение

- » Генеративното моделиране (ГМ) може да се дефинира най-общо, както следва:
  - > ГМ е клон на машинното обучение (МУ), който включва обучение на модел за създаване на нови данни, които са подобни на даден набор от данни.
- » Какво означава това на практика?



# Пример



Да предположим, че имаме набор от данни, съдържащ **снимки на коне**.

Можем да обучим генеративен модел върху този набор от данни, за да уловим правилата, които управляват **сложните взаимоотношения между пикселите** в изображенията на коне.

След това можем да вземем проби от този модел, за **да създадем нови, реалистични изображения** на коне, които **не съществуват в оригиналния набор** от данни.

Този процес е илюстриран на фигурата.





# Данни за обучение

- » За да изградим генеративен модел, се нуждаем от набор от данни, състоящ се от много примери за обекта, който се опитваме да генерираме.
- » Това е известно като **данни за обучение** и една такава точка от данни се нарича **наблюдение**.



# Характеристики на наблюденията

- » Всяко наблюдение се състои от **множество характеристики**:
  - > За проблем с генериране на изображение характеристиките обикновено са **стойностите на отделните пиксели**.
  - > За проблем с генериране на текст характеристиките могат да бъдат **отделни думи** или **групи от букви**.



# Цел на ГМ

- » Целта е **изграждане модели**, които могат да **генерират нови набори от характеристики**, изглеждащи така, сякаш са създадени по **същите правила като оригиналните данни**.
- » Концептуално, за генериране на изображение това е невероятно трудна задача, като се има предвид:
  - > **Огромният брой начини**, по които могат да бъдат **присвоени стойности** на отделни пиксели и
  - > **Относително малкият брой** такива подредби, които **съставляват изображение на обекта**, който се опитваме да генерираме.



# Вероятностни модели

- » Един генеративен модел също трябва да бъде **вероятностен** (а не детерминистичен)
  - > Понеже искаме да можем да изпробваме **различни вариации** на изхода, вместо да получаваме един и същ изход всеки път.
- » Ако нашият модел е просто **фиксирано изчисление** (например вземане на средна стойност на всеки пиксел в набора от данни за обучение) той **не е генеративен**.
- » Генеративният модел трябва да включва **вероятностен компонент**, който **влияе** върху отделните екземпляри, генерирани от модела.



# Вероятностни модели

- » С други думи, можем да си представим, че съществува **някакво неизвестно вероятностно разпределение**, което обяснява защо някои изображения е вероятно да бъдат намерени в обучителния набор от данни, а други изображения не.
- » Нашата работа е:
  - > Да изградим модел, който **имитира това разпределение възможно най-близо** и
  - > След това да пробваме от него да **генерираме нови, различни екземпляри**, които изглеждат така, сякаш биха могли да бъдат включени в оригиналния набор за обучение.





**Генеративно срещу  
дискриминационно моделиране**

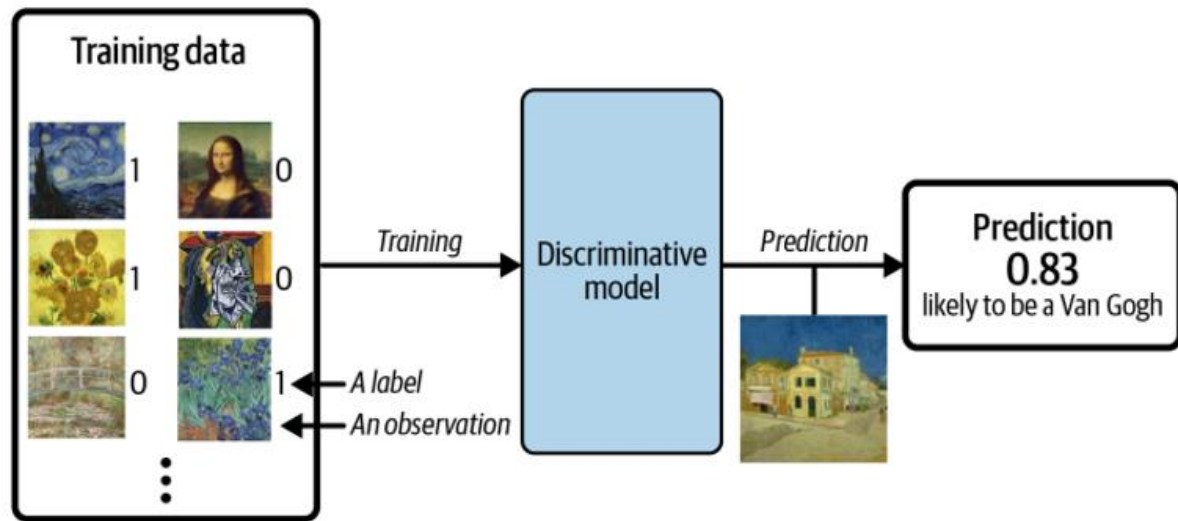


# ДМ

- » За да разберем наистина какво има за цел да постигне ГМ и защо това е важно, е полезно да го сравним с неговия аналог - **дискриминационното моделиране (ДМ)**.
- » Ако сме изучавали МУ, повечето проблеми, с които сме се сблъсквали, ще имат повечето **вероятно са били дискриминационни по природа**.
- » За да разберем разликата, нека разгледаме пример.



# Пример

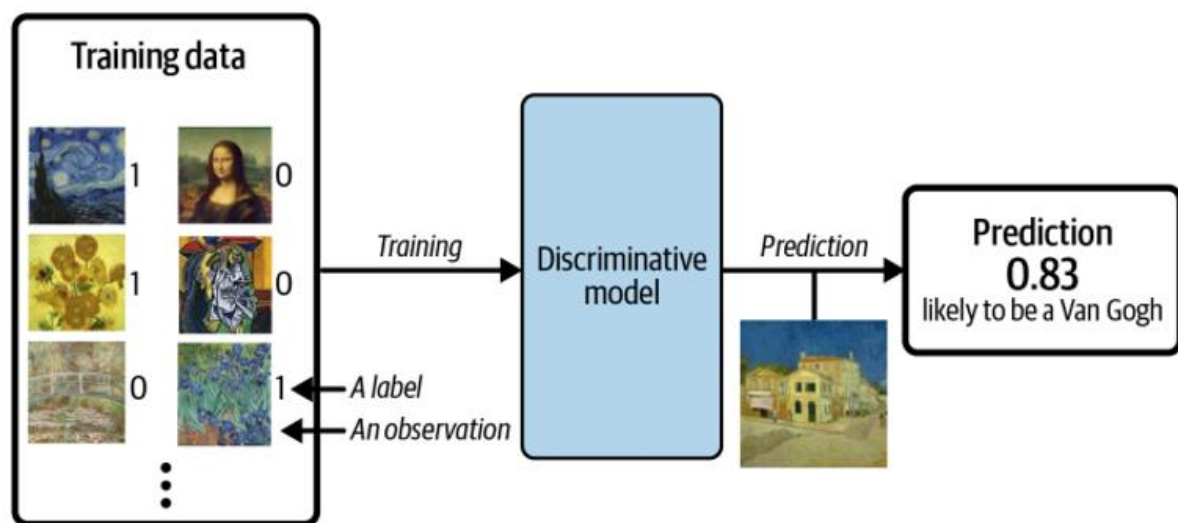


Да предположим, че имаме набор от данни от картини, някои от които са рисувани от Ван Гог, а други от други художници.

С достатъчно данни бихме могли да обучим един дискриминативен модел да **предвижда** дали дадена картина е нарисувана от Ван Гог.



# Пример



Нашият модел би научил, че определени цветове, форми и текстури е **по-вероятно** да показват, че дадена картина е от холандския майстор.

За картини с тези характеристики моделът съответно би **увеличил тежестта** на прогнозата си.

Фигурата показва процеса на ДМ - обърнете внимание как се различава от процеса на ГМ, показан на предишната фигура.



# Етикети

- » При ДМ всяко наблюдение в данните за обучение има **етикет**.
- » За проблем с **двоична класификация** (като нашия дискриминатор на художник) картините на Ван Гог ще бъдат означени с 1, а картините, които не са на Ван Гог, с 0.
- » След това нашият модел научава как да прави разлика между тези две групи и извежда **вероятността** ново наблюдение да има **етикет 1** — т.е. че е нарисувана от Ван Гог.





# Етикети

- » За разлика от това, ГМ **не изисква** наборът от данни да бъде **етикетиран**.
  - > Понеже се занимава с **генерирането на изцяло нови изображения**, вместо да се опитва да **предвиди етикет на дадено изображение**.



# Формални дефиниции

## » Оценки на ДМ $p(y|x)$

- > Т.е., ДМ има за цел да моделира вероятността за етикет  $y$  при дадено  $x$ .

## » Оценки на ГМ $p(x)$

- > Т.е. ГМ има за цел да моделира вероятността за наблюдение на  $x$ .
- > Изпробването на това разпределение ни позволява да генерираме нови екземпляри.



# Формални дефиниции

- » **Условно генеративни модели** - можем също така да изградим генеративен модел за да моделираме условна вероятност  $p(x|y)$  — вероятността да видим наблюдение  $x$  със специфичен етикет  $y$ .
  - > Например, ако нашият набор от данни съдържа различни видове плодове, можем да кажем на нашия генеративен модел да генерира конкретно изображение на ябълка.



# Коментар

- » Важен момент, който трябва да се отбележи, е, че дори и да успеем да изградим перфектен ДМ за идентифициране на картини на Ван Гог, той пак **няма да има представа как да създаде картина**, която прилича на Ван Гог.
- » Той може да **извежда само вероятности** от съществуващи изображения, тъй като това е, което е обучен да прави.
- » Вместо това ще трябва да обучим ГМ и извадка от този модел за да генерираме изображения, които имат голям шанс да принадлежат към оригиналния набор от данни за обучение.



**Възходът на ГМ**





# ДМ като движеща сила

- » Доскоро ДМ беше **движещата сила** на напредъка в МУ.
- » Това е така, защото за всеки дискриминационен проблем съответният проблем с ГМ обикновено е **много по-труден** за справяне.
- » Например, много по-лесно е да обучим модел да предскаже дали една картина е на Ван Гог, отколкото да обучим (от нулата) модел да генерира картина в стил Ван Гог.




# Недостижими генеративни предизвикателства

- » По същия начин е много по-лесно да се обучи модел да предскаже дали страница с текст е написана от Чарлз Дикенс, отколкото да се изгради модел за генериране на набор от параграфи в стила на Дикенс.
- » Доскоро повечето генеративни предизвикателства бяха просто **недостижими** и мнозина се съмняваха, че те някога могат да бъдат разрешени.
- » Креативността се смяташе за чисто човешка способност, която не можеше да се конкурира с ИИ.



# Пример



С развитието на технологиите за МУ обаче това предположение постепенно отслабва.

През последните 10 години много от най-интересните постижения в областта са дошли чрез нови приложения на МУ към задачи за **генеративно моделиране**.

Например фигурата показва удивителния напредък, който вече е постигнат в генерирането на изображения на лицето от 2014 г. насам.



- » Освен че е по-лесно за справяне, ДМ исторически е било **по-лесно приложимо към практически проблеми** в индустрията, в сравнение с ГМ.
- » Например, лекар може да се възползва от модел, който прогнозира дали дадено изображение на ретината показва признаци на глаукома, но не е задължително да има полза от модел, който може да генерира нови снимки на задната част на окото.





- » Това обаче също започва да се променя с разпространението на компании, предлагащи генеративни услуги, насочени към конкретни бизнес проблеми.
- » Например, вече е възможно да получите достъп до API, които генерират оригинални публикации в блогове по определена тема, създават различни изображения на желан продукт във всяка желана ситуация или пишат съдържание за социални медии и рекламно копие, за да съответстват на вашата марка и целево послание.
- » Има също така ясни положителни приложения на ГИИ за индустрии като дизайн на игри и кинематография, където моделите, обучени да извеждат видео и музика, започват да добавят стойност.





**ГМ и ИИ**



# Причини за възхода на ГМ

- » Освен практическите приложения на ГМ (много от които тепърва ще бъдат открити) има **три по-дълбоки причини**, поради които ГМ може да се счита за ключ към отключването на много по-сложна форма на ИИ, извън ДМ.



# Теория

- » Първо, от чисто **теоретична гледна точка**, не трябва да се ограничава МУ до просто категоризиране на данни.
- » За пълнота трябва да се занимаваме и с модели на обучение, които улавят **по-пълно разбиране** на разпространението на данни, **извън конкретни етикети**.
- » Това несъмнено е по-труден проблем за решаване, поради голямата размерност на пространството на възможните изходи и относително малкия брой творения, които бихме класифицирали като принадлежащи към набора от данни.
- » Въпреки това, много от същите техники, които са довели до развитието на ДМ, като **дълбоко учене, могат да бъдат използвани и от генеративни модели**.



# Стимулиране напредъка в други области на ИИ

- » Второ, ГМ сега се използва за стимулиране на напредъка в други области на ИИ, като усилено учене (изследване на обучаващи агенти за оптимизиране на цел в среда чрез проба и грешка).
- » Да предположим, че искаме да обучим робот да ходи по даден терен.
- » Традиционният подход би бил провеждането на много експерименти, при които агентът изпробва различни стратегии на терена или компютърна симулация на терена.
- » С течение на времето агентът ще научи кои стратегии са по-успешни от други и следователно постепенно ще се подобри.



# Стимулиране напредъка в други области на ИИ

- » Предизвикателство с този подход е, че той не е гъвкав, защото е обучен да оптимизира политиката за една конкретна задача.
- » Алтернативен подход, който наскоро придоби популярност, е вместо това да се обучи агентът да научи световен модел на околната среда, използвайки генеративен модел, независимо от каквато и да е конкретна задача.
- » Агентът може бързо да се адаптира към нови задачи, като тества стратегии в собствения си модел на света, а не в реалната среда, която често е по-ефективна от изчислителна гледна точка и не изисква преквалификация от нулата за всяка нова задача.





# Достигане на обща интелигентност

- » И накрая, ако искаме наистина да кажем, че сме изградили машина, която е придобила форма на интелигентност, която е сравнима с тази на човека, ГМ със сигурност трябва да бъде част от решението.
- » Един от най-добрите примери за ГМ в естествения свят е човекът, който чете тази книга.
- » Отделете малко време, за да помислите какъв невероятен генеративен модел сте.
- » Можете да затворите очи и да си представите как би изглеждал един слон от всеки възможен ъгъл.
- » Можете да си представите няколко правдоподобни различни завършека на любимото си телевизионно шоу и можете да планирате седмицата си напред, като работите през различни бъдещи моменти в ума си и предприемате съответните действия.



- » Текущата невронаучна теория предполага, че нашето възприемане на реалността не е много сложен ДМ, опериращ върху нашия сензорен вход, за да произвежда прогнози за това, което преживяваме, но вместо това е генеративен модел, който се обучава от раждането да произвежда симулации на заобикалящата ни среда, които точно съответстват на бъдещето.
- » Някои теории дори предполагат, че резултатът от този генеративен модел е това, което ние директно възприемаме като реалност.
- » Ясно е, че дълбокото разбиране на това как можем да изградим машини, за да придобием тази способност, ще бъде от основно значение за продължаващото ни разбиране на работата на мозъка и общия изкуствен интелект (ОИИ).



**Въвеждащ пример**




# Първият ни ГМ

- » Като начало ще разгледаме пример-играчка на ГМ
- » Ще представим някои от идеите, които ще ни помогнат да работим с по-сложни архитектури, които ще срещнем по-късно в лекционния курс.



# Hello World!



Нека започнем с игра за ГМ само в две измерения.


Избираме правило, което е използвано за генериране на множество от точки  $\mathbf{X}$  на фигурата. Нека наречем това правило  $p_{\text{data}}$ .

Задачата е да изберем **различна точка**  $x = (x_1, x_2)$  в пространството, която изглежда, че е генерирана **от същото правило**.





# Hello World!



Къде избрахме?

Вероятно, използвайки знанията за съществуващите точки от данни, можем да изградим мисловен модел  $p_{model}$  за това, къде в пространството е по-вероятно да се намери точката.

В това отношение  $p_{model}$  е **оценка** на  $p_{data}$ .

Може би сме решили, че  $p_{model}$  трябва да изглежда като на фигурата - **правоъгълник**, където могат да бъдат намерени точки, и област извън него, където няма шанс да се намерят точки.



# Hello World!

- » За да генерираме ново наблюдение, можем просто да изберете произволна точка в правоъгълника или по-формално, извадка от  $p_{\text{model}}$  на разпространение.
- » Поздравления, току-що изградихме първия си генеративен модел!
- » Използвали сме **тренировъчните данни** (черните точки), за да **конструираме модел** (оранжевата област), от който можем лесно да вземем проби за да генерираме други точки, които изглежда принадлежат към набора за обучение.
- » Нека сега формализираме това мислене в рамка, която може да ни помогне да разберем какво се опитва да постигне ГМ.



**Рамка за ГМ**



# Рамка за ГМ

- » Имаме набор данни от наблюдения  $X$ .
- » Предполагаме, че наблюденията са генерирани според някакво **неизвестно разпределение**  $p_{data}$ .
- » Искаме да изградим **генеративен модел**  $p_{model}$ , който имитира  $p_{data}$ .
- » Ако постигнем тази цел, можем да вземем проби от  $p_{model}$  за да генерираме наблюдения, които изглежда са извлечени от  $p_{data}$ .



# Рамка за ГМ

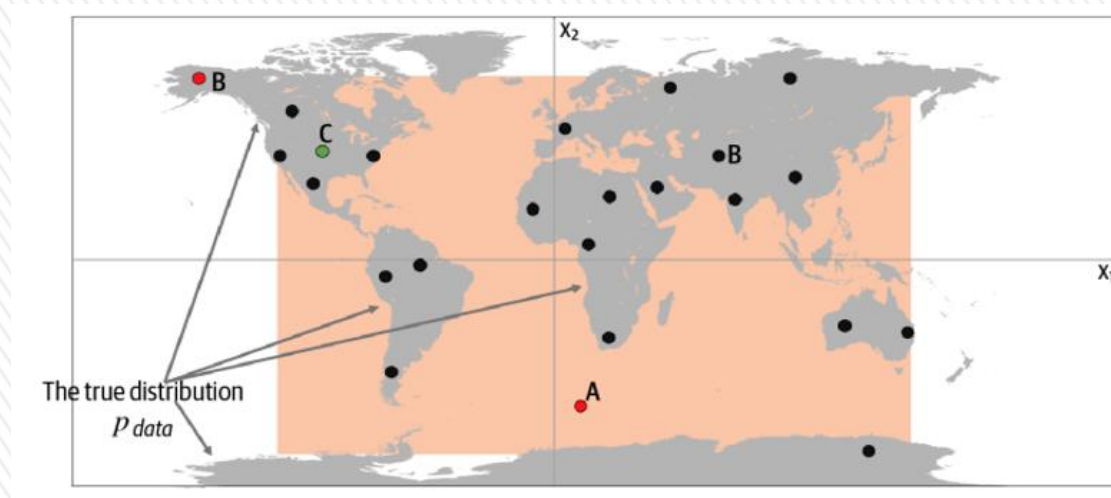
» Следователно желаните свойства на  $p_{\text{model}}$  са:

- > **Точност** - ако  $p_{\text{model}}$  е висок за генерирано наблюдение, то трябва да изглежда така, сякаш е извлечено от  $p_{\text{data}}$ , а ако  $p_{\text{model}}$  е нисък за генерирано наблюдение, то не трябва да изглежда така, сякаш е извлечено от  $p_{\text{data}}$ .
- > **Генериране** - трябва да е възможно лесно да се вземе проба от ново наблюдение от  $p_{\text{model}}$ .
- > **Представяне** - трябва да е възможно да се разбере как различните характеристики на високо ниво в данните са представени от  $p_{\text{model}}$ .





# Hello World!

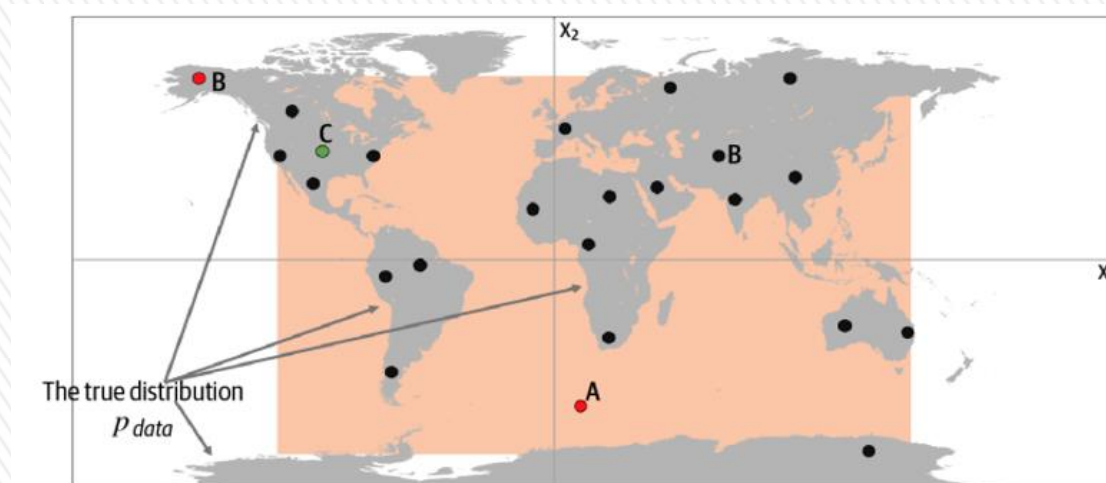


Нека сега разкрием истинската дистрибуция за генериране на данни  $p_{data}$  и да видим как се прилага рамката към този пример.

Както можем да видим от фигурата, правилото за генериране на данни е просто равномерно разпределение върху земната маса на света, без шанс за намиране на точка в морето.



# Hello World!



Ясно е, че нашият модел  $p_{\text{model}}$  е прекалено опростяване на  $p_{\text{data}}$ .

Можем да инспектираме точки A, B и C, за да разберем успехите и неуспехите на нашия модел по отношение на това колко точно имитира  $p_{\text{data}}$ :

- ✓ Точка A е наблюдение, което е генерирано от нашия модел, но не изглежда да е генерирано от  $p_{\text{data}}$ , тъй като е в средата на морето.
- ✓ Точка B никога не би могла да бъде генерирана от  $p_{\text{model}}$ , тъй като се намира извън оранжевата кутия. Следователно нашият модел има някои пропуски в способността си да произвежда наблюдения в целия диапазон от потенциални възможности.
- ✓ Точка C е наблюдение, което може да бъде генерирано от  $p_{\text{model}}$ , а също и от  $p_{\text{data}}$ .



# Обобщение

- » Въпреки недостатъците си, моделът е лесен за вземане на проби, защото е просто равномерно разпределение върху оранжевия правоъгълник.
- » Можем лесно да изберем произволна точка от вътрешността на това поле, за да вземем проба от нея.
- » Също така със сигурност можем да кажем, че нашият модел е просто представяне на основното сложно разпределение, което улавя някои от основните характеристики на високо ниво.
- » Истинското разпределение е разделено на области с много земна маса (континенти) и такива без земна маса (морето).
- » Това е функция от високо ниво, която е вярна и за нашия модел, с изключение на това, че имаме един голям континент, а не много.



# Обобщение

- » Този пример демонстрира основните концепции на ГМ.
- » Проблемите, които ще разгледаме в този лекционен курс, ще бъдат далеч по-сложни и с голямо измерение, но основната рамка, чрез която подходдаме към проблема, ще бъде същата.



**Представително учене**





# Учене на представяне

- » Струва си да се задълбочим малко по-дълбоко в това, което имаме предвид в учене на едно представяне от високо размерни данни.
- » Понеже тази тема ще се повтаря в лекционния курс.



# Пример

- » Да предположим, че искаме да опишем външния вид на някой, който ни търси в тълпа от хора и не знае как изглеждаме.
- » Не бихме започнали с посочване на цвета на пиксел 1 на наша снимка, след това на пиксел 2, след това на пиксел 3 и т.н.
- » Вместо това бихме направили **разумното предположение**, че другият човек **има обща представа** за това как изглежда **средностатистически човек**.
- » Можем само да **коригираме тези базови характеристики** (представени като групи пиксели) като например имам много руса коса или нося очила.



# Пример

- » С не повече от 10 или повече от тези твърдения, човек би могъл да картографира описанието обратно в пиксели за да генерира нашето изображение.
- » Изображението не би било перфектно, но би било достатъчно близко до действителния ни външен вид за да ни намерят сред евентуално стотици други хора, дори ако никога преди не са ни виждали.




# Основна идея

- » Това е основната идея на представителното учене.
- » Вместо да се опитваме да **моделираме директно** високоразмерното пространство на извадката:
  - > Описваме всяка извадка в набора за обучение, използвайки някакво **латентно пространство с по-ниски измерения**
  - > След това научаваме функция за картографиране, която може да вземе точка в латентното пространство и да я картографира към точка в оригиналния домейн.
- » Така, всяка **точка в латентното пространство е представяне на някакво високоразмерно наблюдение.**



# Пример




Какво означава това на практика?

Да предположим, че имаме набор за обучение, състоящ се от **изображения в сива скала** на форми за бисквити (фигурата).





# Пример




За нас е очевидно, че има **две характеристики**, които могат **уникално** да представят всяка от тези форми: **височина** и **ширина**.

Това означава, че можем да преобразуваме всяко изображение в **точка в латентно пространство от само две измерения**, (въпреки че тренировъчният набор от изображения е предоставен във високоразмерно пикселно пространство).



# Пример



По-специално, това означава, че можем също така да създадем изображения на формите, които не съществуват в набора за обучение, чрез прилагане на подходяща функция за картографиране  $f$  към **нова точка в латентното пространство**, както е показано на фигурата.



# Подход

- » Осъзнаването, че оригиналният набор от данни може да бъде описан от по-простото латентно пространство, не е толкова лесно за една машина
  - > Първо трябва да се установи, че височината и ширината са **двете измерения на латентното пространство, които най-добре описват този набор от данни.**
  - > След което да се **научи функцията за картографиране**, която може да вземе точка в това пространство и да я картографира към изображение на бисквитена форма в сиви нюанси.
- » МУ (и по-специално дълбокото учене) ни дава възможност да обучаваме машини, които могат да открият тези сложни взаимоотношения без човешко ръководство.



# Предимства

- » Едно от предимствата на моделите за учене, които използват латентно пространство, е, че можем да извършваме операции, които засягат характеристики от високо ниво на изображението чрез манипулиране на неговия **вектор на представяне** в рамките на по-управляемото латентно пространство.
- » Например, не е очевидно как да регулираме засенчването на всеки отделен пиксел, за да направим изображението на бисквитена форма по-високо.



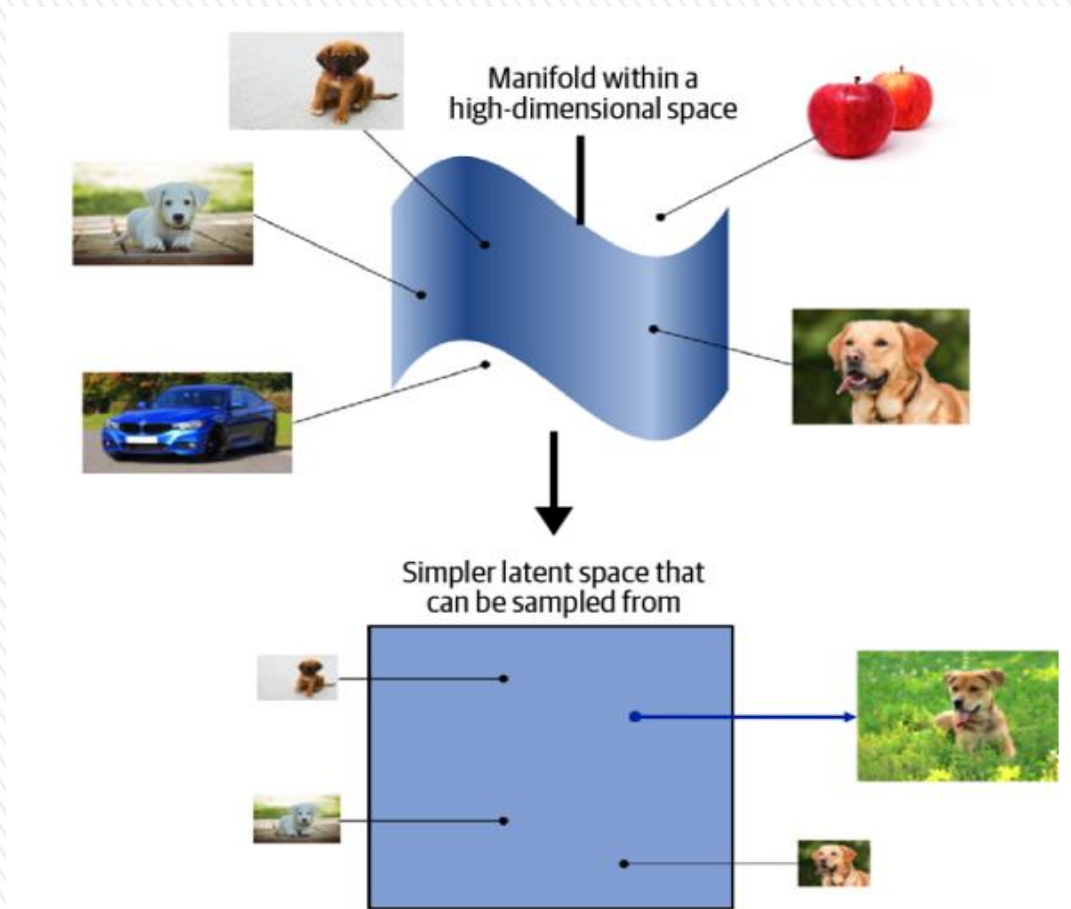
# Предимства

- » В латентното пространство, това е просто случай на **увеличаване на латентното измерение на височината**, след което се прилага функцията за картографиране, за да се върне към домейна на изображението.
- » Друг пример: приложение на подхода не към бисквитени форми, а към лица.






# Обобщение



Концепцията за **кодиране** на обучителния набор от данни в латентно пространство, така че да можем да вземем проби от него и да **декодираме** точката обратно към оригиналния домейн, е **обща за много техники за ГМ**.



# Обобщение



Математически изразено, **техниките на енкодер-декодер** се опитват да **трансформират високо нелинейното многообразие**, в което се намират данните (напр. в пространството на пикселите), в **по-просто латентно пространство**, от което може да се вземе извадка, така че е вероятно **всяка точка в латентното пространство да е представяне на добре оформено изображение**, както е показано на фигурата.



# **Основи на теорията на вероятностите**



# Необходимост

- » Вече видяхме, че ГМ е тясно свързано със статистическото моделиране на вероятностните разпределения.
- » Ето защо има смисъл да се въведат някои основни вероятностни и статистически концепции, които ще бъдат използвани за обяснение на теоретичната основа на моделите.



- » Ако никога не сте изучавали вероятност или статистика, не се притеснявайте.
- » За изграждането на много от моделите на ДУ, които ще разгледаме в лекционния курс, не е от съществено значение да имате задълбочено разбиране на статистическата теория.
- » Въпреки това, за да получим пълна оценка на задачата, с която се опитваме да се справим, струва си да се опитаме да изградим солидно разбиране на основната теория на вероятностите.
- » По този начин ще разполагаме с основите, за да разберем различните семейства генеративни модели, които ще бъдат представени по-късно.





» Като първа стъпка ще дефинираме пет ключови термина, свързвайки всеки един с нашия по-ранен пример за генеративен модел, който моделира картата на света в две измерения.



# Пространство на извадките

- » Пространството на извадките е пълният набор от всички стойности, които едно наблюдение (пример)  $\mathbf{x}$  може да приеме.
- » В примера: примерното пространство се състои от всички точки на географска ширина и дължина  $\mathbf{x} = (x_1, x_2)$  на картата на света.
- » Например  $\mathbf{x} = (40.7306, -73.9352)$  е точка в пространството на извадката (Ню Йорк), която принадлежи на истинското разпределение за генериране на данни.
- »  $\mathbf{x} = (11.3493, 142.1996)$  е точка в пробното пространство, която не принадлежи към истинското разпределение за генериране на данни (това е в морето).

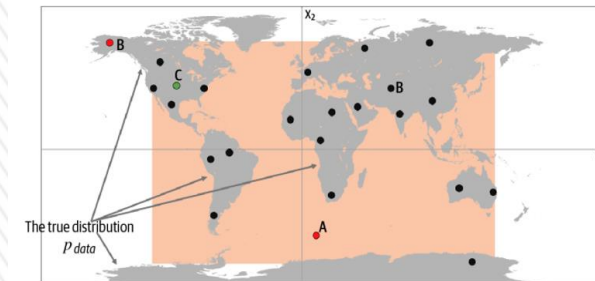


# Функция за плътност

- » Функция за плътност на вероятността (или просто функция за плътност) е функция  $p(x)$ , която преобразува точка  $x$  в пространството на извадките в число между 0 и 1.
- » Интегралът на функцията на плътност върху всички точки в пространството на извадката трябва да е равен на 1, така че да е добре дефинирано разпределение на вероятностите.
- » В примера на картата на света: функцията на плътност на нашия генеративен модел е 0 извън оранжевия правоъгълник и константа вътре в правоъгълника, така че интегралът на функцията на плътност върху цялото пространство на извадките е равен на 1.
- » Докато има само една истинска функция на плътност  $p_{\text{data}}(x)$ , за която се предполага, че е генерирала наблюдавания набор от данни, има безкрайно много функции на плътност  $p_{\text{model}}(x)$ , които можем да използваме, за да оценим  $p_{\text{data}}(x)$ .



# Параметрично моделиране



- » Параметричното моделиране е техника, която можем да използваме за да структурираме нашия подход за намиране на подходящ  $p_{\text{model}}(x)$ .
- » Параметричният модел е семейство от функции на плътност  $p_{\theta}(x)$ , които могат да бъдат описани с помощта на краен брой параметри  $\theta$ .
- » Ако приемем равномерно разпределение като нашето семейство модели, тогава наборът от всички възможни правоъгълници, които можем да нарисуваме на фигурата от примера, е пример за параметричен модел.
- » В този случай има четири параметъра: координатите на долния ляв  $(\theta_1, \theta_2)$  и горния десен  $(\theta_3, \theta_4)$  ъгъл на правоъгълника.
- » Така всяка функция на плътност  $p_{\theta}(x)$  и в този параметричен модел (т.е. всеки правоъгълник) може да бъде уникално представена с четири числа  $\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$ .



# Вероятност

$$\mathcal{L}(\theta | \mathbf{x}) = p_{\theta}(\mathbf{x})$$

Вероятността  $\mathcal{L}(\theta | x)$  на набор от параметри  $\theta$  е функция, която измерва правдоподобността на  $\theta$ , при дадена някаква наблюдавана точка  $x$ .

Дефинира се, както следва:

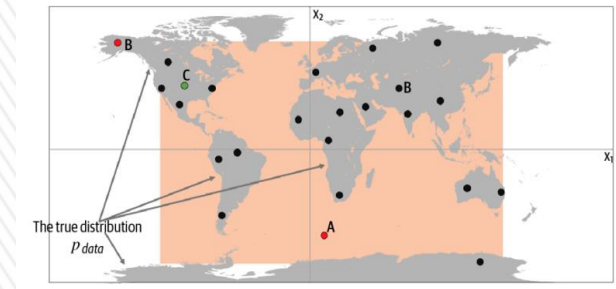
$$\mathcal{L}(\theta | \mathbf{X}) = \prod_{\mathbf{x} \in \mathbf{X}} p_{\theta}(\mathbf{x})$$

Тоест, вероятността за  $\theta$  при дадена наблюдавана точка  $x$  се определя като стойността на функцията на плътност, параметризирана от  $\theta$ , в точката  $x$ .

Ако имаме цял набор от данни  $X$  от независими наблюдения, тогава можем да напишем:







- » В примера с картата на света, оранжево поле, което покрива само лявата половина на картата, би имало вероятност от 0 - не би могло да генерира набор от данни, тъй като наблюдавахме точки в дясната половина на картата.
- » Оранжевият правоъгълник на фигурата има положителна вероятност, тъй като функцията на плътност е положителна за всички точки от данни при този модел.



$$\ell(\theta|\mathbf{X}) = \sum_{\mathbf{x} \in \mathbf{X}} \log p_{\theta}(\mathbf{x})$$

Тъй като произведението на голям брой членове между 0 и 1 може да бъде доста изчислително трудно за работа, често използваме логаритмичната вероятност  $\ell$  вместо това:

Има статистически причини, поради които вероятността е дефинирана по този начин, но също така можем да видим, че това определение интуитивно има смисъл.

Вероятността за набор от параметри  $\theta$  се определя като вероятността да се видят данните, ако истинското разпределение, генериращо данни, е моделът, параметризиран от  $\theta$ .

Има интуитивен смисъл, че фокусът на параметричното моделиране трябва да бъде намирането на оптималната стойност  $\theta^*$  на набора от параметри, която увеличава максимално вероятността за наблюдение на набора от данни  $\mathbf{X}$ .



# Оценка на максималната вероятност

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta | X)$$

Оценката на максималната вероятност е техниката, която ни позволява да оценим набор от параметри  $\theta^\wedge$  - наборът от параметри  $\theta$  на функция на плътност  $p_\theta(x)$ , която е най-вероятно да обясни някои наблюдавани данни  $X$ .

По-формално:

$\theta^\wedge$  се нарича още оценка на максималната вероятност (MLE).

В примера на картата на света MLE е най-малкият правоъгълник, който все още съдържа всички точки в комплекта за обучение.



$$\hat{\theta} = \arg \min_{\theta} (-\ell(\theta|\mathbf{X})) = \arg \min_{\theta} (-\log p_{\theta}(\mathbf{X}))$$

Невронните мрежи обикновено минимизират функция на загуба, така че можем да говорим еквивалентно за намиране на набор от параметри, които минимизират отрицателната логаритмична вероятност:



- » Генеративното моделиране може да се разглежда като форма на оценка на максималната вероятност, където параметрите  $\theta$  са теглата на невронните мрежи, съдържащи се в модела.
- » Опитваме се да намерим стойностите на тези параметри, които увеличават максимално вероятността за наблюдение на дадените данни (или еквивалентно, минимизират  $\log$ -вероятност).





- » Въпреки това, за проблеми с висока размерност обикновено не е възможно да се изчисли директно  $p_{\theta}(x)$  - това е неразрешимо.
- » Различни семейства генеративни модели предприемат различни подходи за справяне с този проблем.



**Таксономия на генеративните модели** ➤

# Три подхода

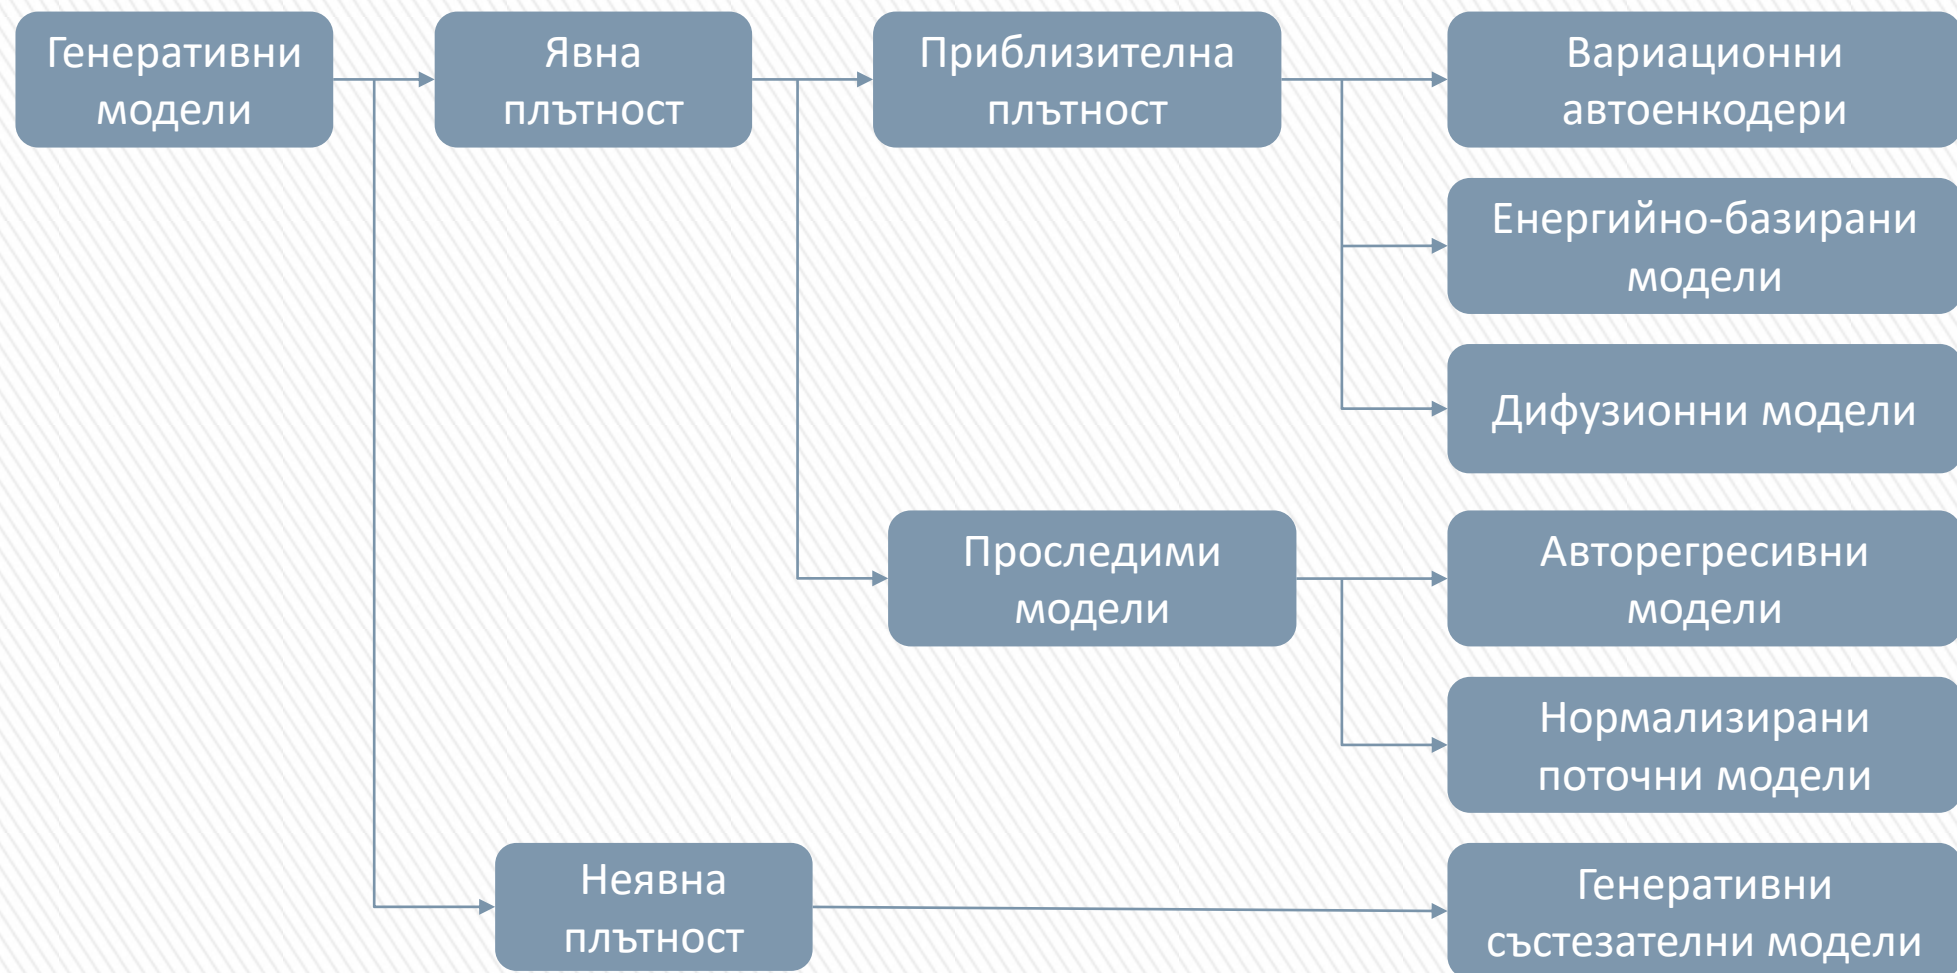
- » Въпреки че всички видове генеративни модели в крайна сметка имат за цел да решат една и съща задача, всички те използват малко по-различни подходи за моделиране на функцията на плътност  $p_{\theta}(x)$ .
- » Съществуват три възможни подхода:
  - > Явно моделиране функцията на плътност, но ограничаване модела по някакъв начин, така че функцията на плътност да е проследима (т.е. да може да бъде изчислена).
  - > Явно моделиране проследимо приближение на функцията на плътността.
  - > Явно моделиране функцията на плътността чрез стохастичен процес, който директно генерира данни.



- » Те са показани на следващата фигура като таксономия, заедно с шестте семейства генеративни модели.
- » Тези семейства не се изключват взаимно – има много примери за модели, които са хибриди между два различни вида подходи.
- » Трябва да мислим за семействата като за различни общи подходи към ГМ, а не като за явни архитектури на модели.



# Видове генеративни модели





# Явни и неявни функции на плътност

- » Първото разделение, което можем да направим, е между модели, при които функцията на плътността на вероятността  $p(x)$  се моделира явно и тези, при които се моделира неявно.
- » Неявните модели на плътност изобщо не целят оценка на плътността на вероятността, а вместо това се фокусират единствено върху създаването на стохастичен процес, който директно генерира данни.
- » Най-известният пример за имплицитен генеративен модел е генеративна състезателна мрежа.
- » Можем допълнително да разделим явните модели на плътност на такива, които директно оптимизират функцията на плътност (модели, които могат да се проследят) и такива, които оптимизират само нейното приближение.



# Податливи модели

- » Податливите модели поставят ограничения върху архитектурата на модела, така че функцията за плътност има форма, която я прави лесна за изчисляване.
- » Например авторегресивните модели налагат подреждане на входните характеристики, така че изходът да може да се генерира последователно - например дума по дума или пиксел по пиксел.
- » Нормализиращите модели на потока прилагат поредица от податливи, обратими функции към просто разпределение, за да генерират по-сложни разпределения.



# Моделите на приблизителна плътност

- » Моделите на приблизителна плътност включват вариационни автоенкодери, които въвеждат латентна променлива и оптимизират приближението на функцията на плътност на ставата. Базираните на енергия модели също използват приблизителни методи, но го правят чрез вземане на проби по веригата на Марков, а не чрез вариационни методи. Дифузионните модели приближават функцията на плътност чрез обучение на модел постепенно да обезшумява дадено изображение, което преди това е било повредено.



# Обобщение

- » Обща нишка, която минава през **всички** типове генеративни модели, е **ДУ**.
- » Почти всички сложни ГМ имат дълбока невронна мрежа в основата си, тъй като те могат да бъдат обучени от нулата, за да научат сложните взаимоотношения, които управляват структурата на данните, вместо да се налага да бъдат твърдо кодирани с информация а приори.







Благодаря за вниманието!

